1 Qué es este dataset

El dataset de Kaggle **Bike Sharing Demand** busca:

predecir cuántas bicicletas serán alquiladas en una hora específica

O sea:

X → condiciones (clima, hora, día, etc)
Y → cantidad de bicicletas alquiladas

La variable objetivo es:

count

Este dataset tiene **10886 filas y 12 columnas**.

Cada fila representa:

1 hora específica

2 Tipo de problema de Machine Learning

Este dataset es:

REGRESIÓN MULTIVARIABLE

Porque:

muchas variables → predicen un número

Ejemplo:

temperatura
humedad
hora
clima
↓
cantidad de bicicletas

NO es:

❌ clasificación
❌ multiclase

Porque **no predice categorías**, predice un **número continuo**.

3 Columnas del dataset (explicación completa)

1 datetime

Ejemplo:

2011-01-01 00:00:00

Significa:

fecha + hora

Es muy importante porque de aquí podemos sacar:

año
mes
día
hora
día de la semana

💡 En ML casi siempre se **descompone en varias variables**.

---

2 season

Valores:

1 = primavera
2 = verano
3 = otoño
4 = invierno

Tipo:

variable categórica

Influye porque la gente usa más bicicletas en ciertas estaciones.

3 holiday

1 = día festivo
0 = no festivo

En festivos puede cambiar la demanda.

4 workingday

1 = día laboral
0 = fin de semana o festivo

Ejemplo:

En días laborales mucha gente usa bici para ir al trabajo.

5 weather

Condiciones climáticas.

Valores:

1 = despejado
2 = nublado / niebla
3 = lluvia ligera
4 = tormenta fuerte

Tipo:

categoría ordinal

6 temp

Temperatura real en **°C**

Ejemplo:

9.84

Tipo:

numérico continuo

7 atemp

Temperatura percibida ("feels like").

Ejemplo:

14.395

A veces puede ser más importante que la real.

8 humidity

Humedad relativa.

Ejemplo:

81

Tipo:

porcentaje

9 windspeed

Velocidad del viento.

Tipo:

numérico continuo

Si hay mucho viento → menos bicicletas.

Casual

Número de usuarios **no registrados**.

11 registered

Número de usuarios **registrados**.

12 count ★

TOTAL de bicicletas alquiladas.

count = casual + registered

Este es el **target**.

4 Variables que NO debemos usar

Muy importante.

No debemos usar:

casual
registered

porque:

count = casual + registered

Si los usamos, el modelo **estaría viendo la respuesta**.

Eso sería **data leakage**.

Por eso usaremos:

season
holiday
workingday
weather
temp
atemp
humidity
windspeed
datetime

---

5 Valores nulos

Este dataset tiene:

0 valores nulos

Por lo tanto:

no necesitamos imputación

---

6 Balanceo

El balanceo solo aplica en:

clasificación

Como esto es **regresión**, **NO se balancea**.

---

7 Qué vamos a predecir

Nuestro modelo aprenderá:

X = condiciones climáticas + tiempo
Y = count

Ejemplo:

hora = 8am
temperatura = 20
humedad = 60
clima = despejado
↓

predicción:
250 bicicletas

---

8 Usaremos todas las columnas?

Usaremos:

season
holiday
workingday
weather
temp

atemp
humidity
windspeed

Y de **datetime** sacaremos:

hour
day
month
weekday

No usaremos:

casual
registered